



杨浩然

求职意向: AI Infra / 大模型算法 · LLM 推理与训练基建

13391186557 · youn_hr@126.com · 上海 · 深圳 · hryang1130.github.io

◆ 教育背景

2026/09 – 至今	香港大学 人工智能 · 硕士 计算及数据科学学院 (School of Computing and Data Science) 主修课程: Deep Learning、Large Language Model、Nature Language Process
2019/09 – 2023/06	四川大学 电子信息工程 · 本科 主修课程: C++ 程序设计、数据结构、操作系统、编译原理、优化算法、图像处理

◆ 工作经验

2026/06 – 2026/08	卓驭科技 自动驾驶系统工程师 模型后训练 · 数据挖掘 - 参与自动驾驶模型后训练 (post-training) 全流程, 包括训练数据构建、模型微调与效果评估 - 负责数据挖掘与数据清洗流程, 从原始驾驶数据中挖掘高价值样本, 支撑模型迭代
2024/07 – 2026/05	文远知行 Infra 系统工程师 自动驾驶车载 Infra · 类 ROS 框架 · 系统性能优化 - 负责自动驾驶车载后端业务模块的开发与维护, 完成系统稳定性优化, 保障车端自驾系统高可靠、高效率运行 - 基于自研类 ROS 框架开发系统模块监控体系, 完成数据落盘、实时上报及分布式部署 - 负责自动驾驶与底盘线控交互中间件的开发及维护, 优化模块通信逻辑, 提升系统整体交互性能 - 承担车端 Oncall 工作, 处理现场部署、程序 Crash 等问题, 快速定位并解决系统故障
2023/07 – 2024/07	上海宇量昇科技有限公司 软件工程师 高精度计算模块 · 算法工程化 · 性能优化 - 负责高精度计算模块的算法工程化开发, 将算法逻辑转化为可落地的工程代码, 实现模块实际业务应用 - 参与业务组件的模块化重构与性能优化, 完成核心功能的首次交付, 提升组件复用性与运行效率

◆ 项目经历

个人项目	LlmGo — LLM 全链路工作流: 训练 → 微调 → 量化 → 推理部署 PyTorch · transformers · LoRA · llama.cpp · GGUF 量化 · Go (Gin) · Docker - 从零训练 LLaMA 架构小模型 (约 4M 参数、BPE 分词、GQA), 自写 GGUF 导出器绕过官方分词器白名单, 并用 llama.cpp 量化至 Q4_K_M, 体积压缩至 F16 的约 1/4 - 搭建量化与性能度量链路: imatrix 校准 + 多方案体积 / 困惑度对比, 统一测量首 token 延迟、预填充与解码吞吐、服务端内存, 并评估 KV cache 量化的额外代价 - 扩展两条模型侧实验链路: LoRA 指令微调 (合并回 HF 权重后复用同一部署链路); draft + target 投机解码, 校验词表一致性并实测接受率与解码加速比
------	--

- 基于 Go（Gin）开发推理网关，对外提供 OpenAI 兼容 API 与流式输出，Docker Compose 一键编排 llama-server 与网关服务
- 实现可视化编排界面（画布拖拽 + 列表勾选双视图、预设模板）：11 个流水线节点按拓扑序执行，SSE 实时回传日志，每个阶段自动产出 Markdown 报告与耗时总结

核心开发	WeTalk — 基于 C++ 的全栈分布式即时通讯系统 QT · gRPC · Boost · Asio · 高并发长连接 负责 DispatchServer 网关开发，提供 HTTP 接口实现登录注册，通过 gRPC 完成服务分发与认证 基于 Asio 实现 TCP 长连接异步通信，池化 io_context 提升系统并发能力；服务端按模块拆分、支持分布式部署，状态管理与认证服务解耦
------	---

专业技能

C++PythonGoPyTorchTransformersLoRA / SFTGGUFDockergRPCROS / ROS2Linux多线程与并发性能调优
--

编程语言	C++：熟悉 C++11/17 新标准、OOP、泛型编程、STL 与模板；掌握内存管理与多线程编程，了解 Boost 及 RTMP / SRT / ffmpeg 流媒体框架 Python：熟悉 Flask / FastAPI 框架与 PyTorch、OpenCV 等库，具备数据处理与脚本工程化能力 其他：了解 Go（goroutine / channel、Gin）与 MySQL / Redis
AI / 大模型	模型与数据：模型后训练（post-training）、数据挖掘与数据集构建 框架与工具：PyTorch / TensorFlow、LangChain、LlamaCpp、ONNX 推理框架
中间件与协议	IO 多路复用、HTTP/HTTPS、WebSocket、MQTT、gRPC / Protobuf、ROS / ROS2、自动驾驶部署标定流程
工程工具	Git、g++ / CMake / Bazel、GDB / Valgrind、Perf / Top / Htop，能完成开发全流程工程化落地与性能调优

自我评价

具备自动驾驶模型后训练与数据挖掘的工程实践，以 C++ 与 Python 为主要开发语言、工程功底扎实；具备算法工程化、模块化重构、系统性能优化的实操能力，能独立完成后端模块与 Infra 系统的开发、部署与问题排查；近期把这条链路延伸到 LLM，独立完成小模型的训练、LoRA 微调、GGUF 量化到 Go 网关部署，并用困惑度、延迟与吞吐等指标做评测对比。
