



杨浩然

求职意向：AI Infra / 大模型算法 · LLM 推理与训练基建

18328377179 · youn_hr@126.com · 上海 · hryang1130.github.io

◆ 教育背景

2026/09 – 至今

香港大学 人工智能 · 硕士

计算及数据科学学院 (School of Computing and Data Science)

主修课程：Deep Learning、Large Language Model、Nature Language Process

2019/09 – 2023/06

四川大学 电子信息工程 · 本科

主修课程：C++ 程序设计、数据结构、操作系统、编译原理、优化算法、图像处理

◆ 工作经验

2026/06 – 2026/08

卓驭科技 自动驾驶系统工程师

模型后训练 · 数据挖掘

- 参与自动驾驶模型后训练 (post-training) 全流程，包括训练数据构建、模型微调与效果评估
- 负责数据挖掘与数据清洗流程，从原始驾驶数据中挖掘高价值样本，支撑模型迭代

2024/07 – 2026/05

文远知行 Infra 系统工程师

自动驾驶车载 Infra · 类 ROS 框架 · 系统性能优化

- 负责自动驾驶车载后端业务模块的开发与维护，完成系统稳定性优化，保障车端自驾系统高可靠、高效率运行
- 基于自研类 ROS 框架开发系统模块监控体系，完成数据落盘、实时上报及分布式部署
- 负责自动驾驶与底盘线控交互中间件的开发及维护，优化模块通信逻辑，提升系统整体交互性能
- 承担车端 Oncall 工作，处理现场部署、程序 Crash 等问题，快速定位并解决系统故障

2023/07 – 2024/07

上海宇量昇科技有限公司 软件工程师

高精度计算模块 · 算法工程化 · 性能优化

- 负责高精度计算模块的算法工程化开发，将算法逻辑转化为可落地的工程代码，实现模块实际业务应用
- 参与业务组件的模块化重构与性能优化，完成核心功能的首次交付，提升组件复用性与运行效率

◆ 项目经历

个人项目

llm_go — LLM 全链路工作流：训练 → 微调 → 量化 → 推理部署

PyTorch · transformers · LoRA · llama.cpp · GGUF 量化 · Go (Gin) · Docker

- 从零训练 LLaMA 架构小模型 (约 4M 参数、BPE 分词、GQA)，自写 GGUF 导出器绕过官方分词器白名单，并用 llama.cpp 量化至 Q4_K_M，体积压缩至 F16 的约 1/4

- 搭建量化与性能度量链路：imatrix 校准 + 多方案体积 / 困惑度对比，统一测量首 token 延迟、预填充与解码吞吐、服务端内存，并评估 KV cache 量化的额外代价
- 扩展两条模型侧实验链路：LoRA 指令微调（合并回 HF 权重后复用同一部署链路）；draft + target 投机解码，校验词表一致性并实测接受率与解码加速比
- 基于 Go（Gin）开发推理网关，对外提供 OpenAI 兼容 API 与流式输出，Docker Compose 一键编排 llama-server 与网关服务
- 实现可视化编排界面（画布拖拽 + 列表勾选双视图、预设模板）：11 个流水线节点按拓扑序执行，SSE 实时回传日志，每个阶段自动产出 Markdown 报告与耗时总结

核心开发

WeTalk — 基于 C++ 的全栈分布式即时通讯系统

QT · gRPC · Boost · Asio · 高并发长连接

- 负责 DispatchServer 网关开发，提供 HTTP 接口实现登录注册，通过 gRPC 完成服务分发与认证
- 基于 Asio 实现 TCP 长连接异步通信，池化 io_context 提升系统并发能力
- 完成 QT 客户端开发与服务端模块化设计，支持分布式部署，实现状态管理与认证服务解耦

专业技能

C++PythonGoPyTorchONNXLangChaingRPCProtobufAsioQtBoostROS / ROS2

CMake / BazelGDB / ValgrindMySQL / RedisLinuxGit多线程与并发性能调优TransformersLoRA / SFT

GGUF Docker

编程语言

C++：熟悉 C++11/17 新标准、OOP、泛型编程、STL 与模板；掌握内存管理与多线程编程，了解 Boost 及 RTMP / SRT / ffmpeg 流媒体框架

Python：熟悉 Flask / FastAPI 框架与 PyTorch、OpenCV 等库，具备数据处理与脚本工程化能力

其他：了解 Go（goroutine / channel、Gin）与 MySQL / Redis

AI / 大模型

模型与数据：模型后训练（post-training）、数据挖掘与数据集构建

框架与工具：PyTorch / TensorFlow、LangChain、LlamaCpp、ONNX 推理框架

中间件与协议

IO 多路复用、HTTP/HTTPS、WebSocket、MQTT、gRPC / Protobuf、ROS / ROS2、自动驾驶部署标定流程

工程工具

Git、g++ / CMake / Bazel、GDB / Valgrind、Perf / Top / Htop，能完成开发全流程工程化落地与性能调优

自我评价

具备自动驾驶模型后训练与数据挖掘的工程实践，以 C++ 与 Python 为主要开发语言、工程功底扎实；具备算法工程化、模块化重构、系统性能优化的实操能力，熟悉后端开发核心技术、主流通信协议与工程化工具，能独立完成后端模块与 Infra 系统的开发、部署与问题排查；近期把这条链路延伸到 LLM，独立完成小模型的训练、LoRA 微调、GGUF 量化到 Go 网关部署，并用困惑度、延迟与吞吐等指标做评测对比。